

OPTIMASI KERANGKA KERJA METODE SIDIK JARI PADA TEKNIK PEMOSISIAN OBJEK DALAM RUANG BERBASIS WIFI LEWAT PENERAPAN KLASTERISASI HYBRID DBSCAN-K MEANS DAN IMPROVED WKNN

Nicolas Christianto¹, Dwi Joko Suroso², Muhammad Reza Kahar Aziz³

^{1,2}Department Teknik Nuklir dan Teknik Fisika FT UGM

³Teknik Elektro ITERA

¹nicolaschristianto@mail.ugm.ac.id

²dwi.jokosuroso@ugm.ac.id

³reza.kahar@el.itera.ac.id

Abstract – Beberapa tahun terakhir ini, perkembangan teknik pemosision objek dalam ruang menjadi topik hangat dalam penelitian komunikasi jaringan nirkabel. Salah satu fokus penelitian tersebut diantaranya pengembangan metode pemosision berbasis sidik jari. Arah pengembangan metode sidik jari saat ini adalah mengurangi kompleksitas komputasi dan meningkatkan akurasi pemosision lewat upaya pembentukan klaster. Sejumlah kerangka kerja metode sidik jari yang ada telah mampu mengurangi kompleksitas komputasi namun di sisi lain belum secara baik dalam menangani data-data *outlier*. Atas dasar itu penulis mengusulkan kerangka baru yang berfokus pada penanganan data *outlier* melalui optimasi kerangka pada tahap *offline* dan *online*. Optimasi tahap *offline* dilakukan lewat penerapan teknik klasterisasi bertingkat (*hybrid clustering*) dan optimasi tahap *online* dilakukan lewat kombinasi representasi jarak fisik dan spasial data. Kerangka optimasi lantas dibandingkan dengan sejumlah kerangka *state-of-art*. Hasil penelitian menunjukkan kerangka optimasi mampu menurunkan rerata RMSE pemosision sebesar 13.78% pada uji penjejakan diagonal kiri, serta 17.65% pada uji penjejakan diagonal kanan untuk seluruh skenario lingkungan yang diujikan.

Kata kunci: Teknik Pemosision Dalam Ruang, Kerangka Metode Sidik Jari, Deteksi *Outlier*, Klasterisasi DBSCAN, *Improved-WKNN*.

I. PENDAHULUAN

Dalam beberapa tahun terakhir, perkembangan teknologi pemosision objek dalam ruang menjadi topik hangat dalam penelitian tentang komunikasi jaringan nirkabel. Hal ini diikuti dengan pertumbuhan sejumlah aplikasi layanan berbasis lokasi (*location based services*) yang dalam implementasinya memerlukan informasi posisi bagi pengguna. Namun penggunaan layanan berbasis lokasi dalam ruang masih menemui sejumlah

keterbatasan. Sistem navigasi global yang biasa dipakai pada *Global Positioning System* (GPS) tidak serta merta memberikan kinerja pemosision yang memuaskan apabila diterapkan pada lingkungan dalam ruang [1]. Hal ini dapat dipengaruhi oleh sejumlah faktor destruktif sinyal seperti pemblokiran dan efek *multipath* yang ada.

Terdapat sejumlah metode pemosision objek dalam ruang yang ada saat ini diantaranya [2]; 1) Metode

triangulasi dengan penggunaan properti sinyal berbasis sudut, misalnya *Angle of Arrival* (AOA). 2) Metode trilaterasi dengan penggunaan properti sinyal berbasis jarak, misalnya *Time of Arrival* (TOA) atau *Time Difference of Arrival* (TDOA). 3) Metode *scene analysis* dengan penggunaan properti sinyal berbasis kuat sinyal yang diterima atau *Received Signal Strength Indicator* (RSSI). Metode sidik jari (*fingerprint technique*) merupakan salah satu jenis penerapan dari metode *scene analysis* yang paling banyak digunakan saat ini [3].

Dibandingkan dengan metode pertama dan kedua, metode sidik jari sangat bergantung pada tempat atau ruangan yang dipakai, artinya struktur *database* sidik jari mampu secara adaptif menyesuaikan kondisi ruangan yang berubah-ubah [4]. Aspek ini yang coba ditonjolkan pada metode sidik jari meskipun bila ditinjau dari aspek akurasi pemosisian masih terbilang sedang dibandingkan dua metode sebelumnya.

Metode sidik jari terbagi atas dua tahapan meliputi, tahap *offline* dan *online*. Pada tahap *offline*, pengguna (*mobile unit*) mengumpulkan nilai RSSI dari masing-masing titik akses nirkabel atau *Access Point* (AP) pada setiap titik referensi atau *Reference Point* (RP). Masing-masing RP telah diketahui posisi koordinatnya relatif terhadap ruang. Nilai RSSI yang dikumpulkan kemudian disimpan dalam *database* sidik jari. Pada tahap *online*, pengguna memperoleh nilai RSSI *online* dari posisi yang ingin ditentukan koordinatnya, kemudian RSSI tersebut dicocokkan dengan RSSI *offline* dalam *database*. Hasil proses pencocokan menghasilkan nilai estimasi RP sebagai perkiraan koordinat posisi.

Saat ini, arah penelitian utama metode sidik jari adalah mengurangi kompleksitas komputasi dan meningkatkan akurasi pemosisian lewat upaya pembentukan klaster pada tahap pengolahan data mentah (*database*) [5], [6]. Melalui pembentukan klaster, kompleksitas pencarian estimasi posisi pada tahap *online* dapat dibatasi untuk sejumlah klaster tertentu saja. Hal ini mampu mengurangi beban komputasi yang digunakan sekaligus meningkatkan efisiensi pemosisian.

Sejumlah peneliti telah mengusulkan beberapa kerangka kerja (*framework*) dalam penggunaan metode klasterisasi sidik jari, diantaranya klasterisasi K-means dan *Density-Based Spatial Clustering of Applications with Noise* (DBSCAN) [4], [7]. Kerangka berbasis klasterisasi K-means dinilai baik dalam mengatasi data berdimensi besar, namun kerangka ini tidak cukup baik dalam mengatasi *outlier* atau data-data gangguan (*noise data*). Padahal dalam praktiknya pembentukan *database* sidik jari dalam ruang sangatlah rentan terhadap gangguan dari lingkungan seperti *multipath effect* atau interferensi sinyal. Kehadiran data gangguan mampu secara serius menurunkan kinerja algoritma pencocokan yang akan dipakai pada tahap *online*.

Di sisi lain, kehadiran data gangguan dapat diatasi oleh klasterisasi DBSCAN. Namun penggunaan klasterisasi DBSCAN tidak cukup baik dalam mengatasi data-data berdimensi besar. Proses penentuan klaster pada tahap *online* dengan DBSCAN juga secara tidak langsung dapat mengubah definisi titik tetangga (*neighbours points*) yang sebelumnya dibentuk pada tahap *offline*. Apabila hal ini terjadi maka entitas klaster

yang telah terkategorii sebelumnya dapat berubah dan usang.

Pada pencocokan tahap *online*, data-data baru perlu dikategorii terlebih dahulu ke dalam data klaster terkategorii inti (*core*) atau terkategorii *noise*. Nantinya perlakuan yang diberikan pada masing-masing data terkategorii akan berbeda. Data terkategorii inti akan diproses dengan algoritma pencocokan menggunakan model klaster terpilihnya, sementara data terkategorii *noise* akan diproses dengan algoritma pencocokan baru. Algoritma K *Nearest Neighbors* Bobot (WKNN) diusulkan sebagai algoritma pencocokan baru dalam menangani data terkategorii *noise* pada tahap *online* [4]. Namun penggunaan WKNN masih belum cukup akurat dikarenakan algoritma ini hanya mengeksplorasi fitur RSSI dalam bidang spasialnya saja. Mengingat data baru yang diproses merupakan data terkategorii *noise*, sudah tentu korespondensi fitur data baru yang dimiliki dengan fitur dalam *database* akan sangat berbeda.

Penelitian ini memberi batasan berupa jumlah target adalah satu dengan keberadaan *Access Point* (AP) berjumlah empat. Skenario lingkungan uji dibagi ke dalam lima skenario meliputi skenario tanpa gangguan, dengan objek penghalang, gangguan fluktuatif pusat, gangguan fluktuatif kuadran satu, dan gangguan fluktuatif kuadran tiga. Perbandingan antar kerangka kerja juga difokuskan pada penggunaan model induk K-*Nearest Neighbors* [8].

Tujuan penelitian ini adalah mengkaji performa kerangka optimasi usulan dengan membandingkannya dengan sejumlah kerangka *state-of-art* teknik pemasian objek dalam ruang berbasis sidik jari yang ditinjau dari aspek akurasi

atau eror pemasian antar kerangka-kerangka tersebut.

II. METODOLOGI

II.A. Alat dan Bahan

Alat pada penelitian ini terdiri dari perangkat keras dan perangkat lunak. Perangkat keras meliputi ESP32 Dev-kit yang digunakan sebagai *Access Point* (AP) dan *Station* (STA), serta Raspberry Pi 3 B+ digunakan untuk kebutuhan *server side* seperti *broker*, *database*, dan *data bridge*. Perangkat lunak meliputi Arduino IDE sebagai lingkungan pengembangan ESP32 dan *Jupyter Notebook* dengan Python versi 3.7 sebagai perangkat analisis data.

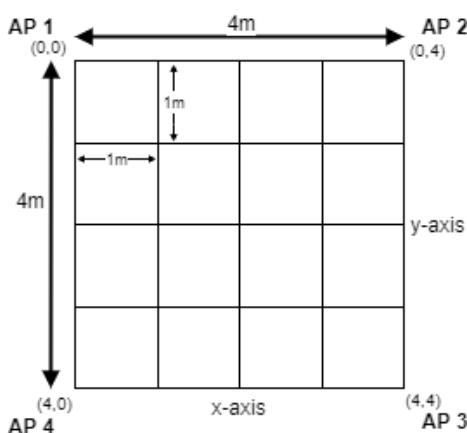
II.B. Tata Laksana Penelitian

Secara ringkas tata laksana penelitian terbagi menjadi delapan tahapan meliputi studi pustaka, penyediaan alat bahan, penyusunan denah eksperimen, perancangan sistem akuisisi data, pengumpulan data sidik jari, perancangan kerangka pembanding dan optimasi, analisis dan evaluasi, serta pembuatan laporan penelitian. Seluruh rangkaian tata laksana penelitian digambarkan pada Gambar 1.

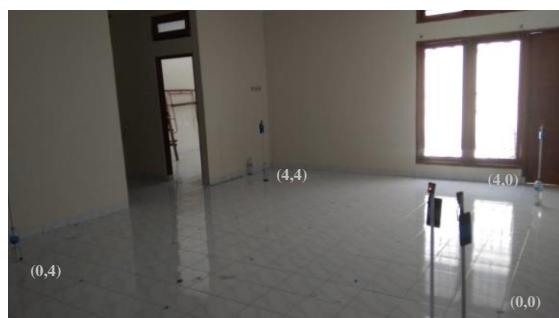


II.B.1) Denah Eskperimen

Denah eksperimen merupakan tempat pengambilan data penelitian dan pengujian sejumlah skenario lingkungan uji. Denah eksperimen dibangun pada area petak persegi dengan panjang x lebar $16m^2$ dan rapat petak 1m. Setiap titik dalam petak dilabeli sebagai RP guna membantu proses pembentukan model algoritma pemosisian. Gambaran denah eksperimen secara lebih jelas dapat dilihat pada Gambar 2 dan 3.



Gambar 2. Skema denah eksperimen.



Gambar 3. Dokumentasi denah eksperimen.

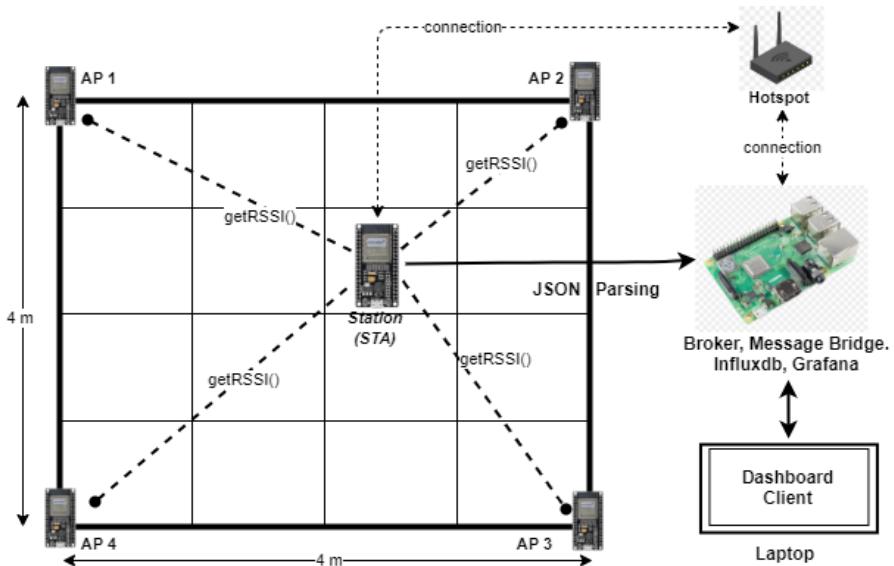
II.B.2) Sistem Akuisisi Data

Sistem dirancang mampu mengakuisisi data RSSI untuk kemudian diolah menjadi format *Comma Separated Value* (CSV) guna keperluan analisis. Penjabaran pada bagian ini menitikberatkan pada konfigurasi ESP32 serta sistem akuisisi data RSSI secara utuh.

Konfigurasi ESP32 pada sistem terbagi ke dalam dua jenis yakni konfigurasi *Access Point* (AP) dan *Station* (STA). Sebagai STA, ESP32 akan membaca vektor nilai RSSI dari keempat AP yang diletakkan pada setiap ujung denah eksperimen. Proses pembacaan ini merupakan proses pemindaian (*scanning*) yang mengembalikan vektor nilai RSSI dalam satuan dBm. Hasil dari proses pemindaian akan dikirimkan ke *server broker* untuk diproses lebih lanjut.

Secara keseluruhan sistem akuisisi data terdiri atas komponen *client* dan *server*. Kedua komponen tersebut berjalan di atas protokol MQTT atau transportasi *publish subscribe*. *Client* (ESP32 STA) akan melakukan proses *publish* yakni mengirim data berupa vektor nilai RSSI ke *server broker* melalui *channel* atau *topic* tertentu. *Server broker* yang bertindak sebagai perantara (*message queue*) akan menerima data tersebut untuk diteruskan ke *NodeRed* sebagai jembatan data (*data bridge*). *NodeRed* yang sebelumnya telah melakukan proses *subscribe* (meminta data dengan topik tertentu) ke *server broker* akan mengirim data ke dalam *database InfluxDB*.

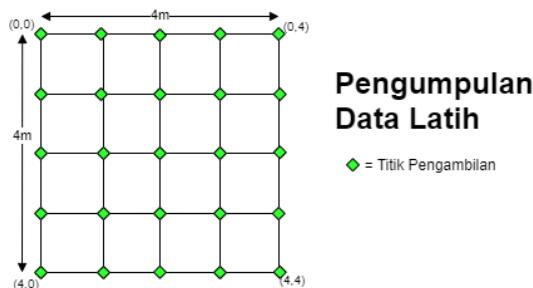
Setelah tersimpan dalam *database*, *server Grafana* akan melakukan proses *query* terhadap seluruh data secara *real-time*. Hasil *query* akan ditampilkan pada dasbor *client* berupa visualisasi *trend* vektor nilai RSSI. Dari dasbor ini pula data RSSI akan diekstrak ke dalam format CSV. Data akan diekstrak sesuai dengan minat durasi (*time of interest*) yang diinginkan. Minat durasi yang dipilih pada penyusunan sistem kali ini adalah dua menit waktu pengambilan data. Gambar 4 menunjukkan skema blok diagram sistem akuisisi data.



Gambar 4. Skema sistem akuisisi.

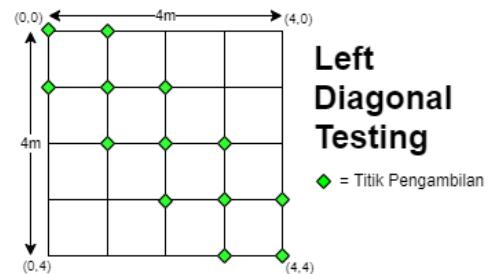
II.B.3) Pengumpulan Data Sidik Jari

Pengumpulan data sidik jari tersusun atas pengumpulan data latih dan tes. Pada pengumpulan data latih, proses pemindaian akan dilakukan terhadap seluruh RP dalam denah eksperimen. Proses ini berjalan dari titik (0,0) ke titik (4,0), kemudian turun ke titik (4,1), lalu ke titik (0,1), begitu seterusnya sampai titik (4,4). Gambar 5 menggambarkan skema pengumpulan data latih.

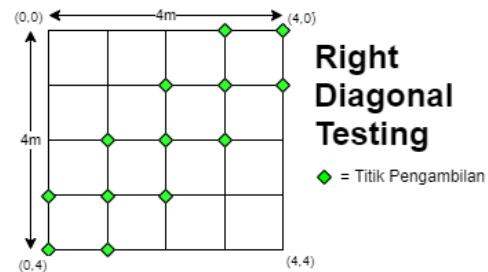


Gambar 5. Pengambilan data latih.

Pada pengumpulan data tes, proses pemindaian hanya dilakukan terhadap sejumlah RP tertentu saja. Pengumpulan data tes yang dilakukan terbagi ke dalam pengumpulan data tes diagonal kiri (Gambar 6) dan diagonal kanan (Gambar 7).

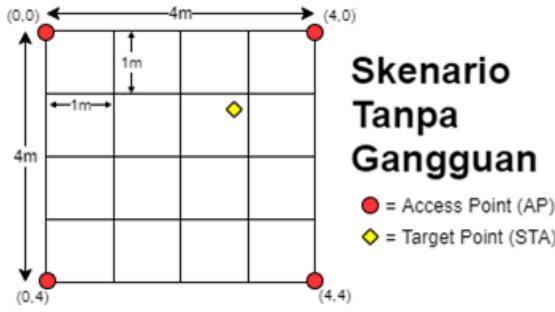


Gambar 6. Pengambilan data tes diagonal kiri.

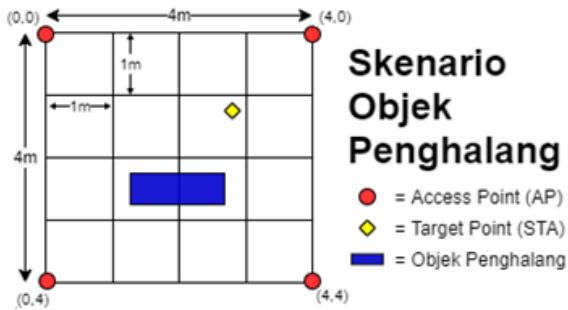


Gambar 7. Pengambilan data tes diagonal kanan.

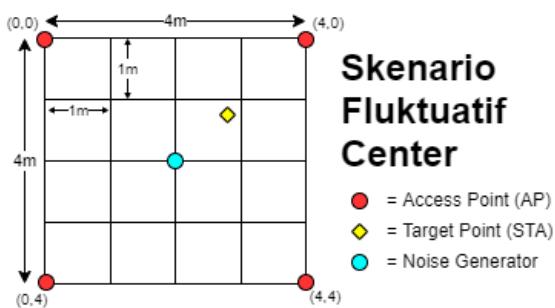
Disamping skema pengumpulan sidik jari, terdapat juga skenario lingkungan uji yang diajukan penulis sebagai skema perbandingan antar kerangka kerja. Skenario tersebut meliputi skenario tanpa gangguan (Gambar 8), dengan objek penghalang (Gambar 9), gangguan fluktuatif pusat (Gambar 10), gangguan fluktuatif kuadran satu (Gambar 11), gangguan fluktuatif kuadran tiga (Gambar 12).



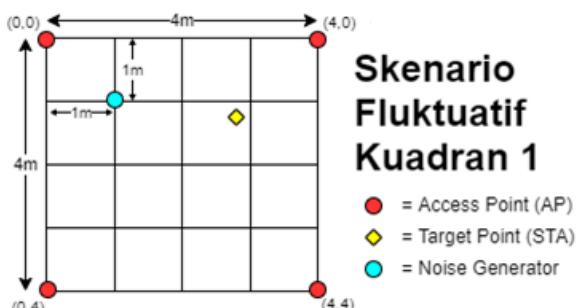
Gambar 8. Skenario tanpa gangguan.



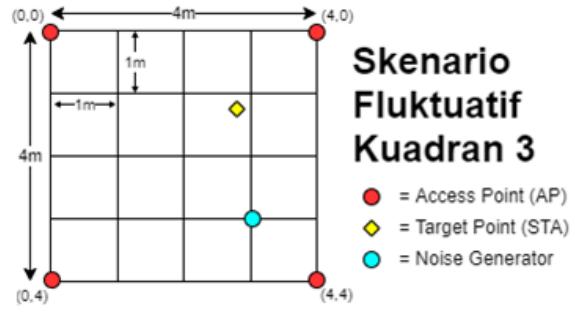
Gambar 9. Skenario dengan objek penghalang.



Gambar 10. Skenario gangguan fluktuatif pusat.



Gambar 11. Skenario gangguan fluktuatif kuadran satu..



Gambar 12. Skenario gangguan fluktuatif kuadran tiga.

Skenario gangguan fluktuatif dibangun dengan menciptakan pembangkit sinyal baru dengan frekuensi kerja dan protokol jaringan yang serupa. Spesifikasi pembangkit sinyal baru ditunjukkan pada Tabel 1.

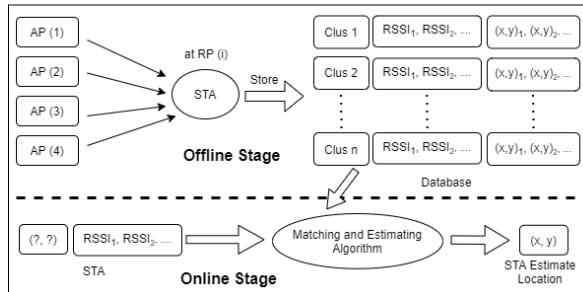
Tabel 1. Spesifikasi Pembangkit Sinyal.

No.	Nama Karakteristik	Deskripsi	
1.	Rentang frekuensi	2412 ~ 2484 MHz	
2.	Wi-Fi wireless standard	IEEE 802.11 b/g/n	
3.	Data rate	20 MHz	11b: 1, 2, 5.5 and 11 Mbps 11g: 6, 9, 12, 18, 24, 36, 48, 54 Mbps 11n: MCS0-7, 72.2 Mbps (Max)
		40 MHz	11n: MCS0-7, 150 Mbps (Max)
4.	Tipe antena	Antena PCB, antena IPEX	

II.B.4) Kerangka Optimasi & Pembanding

Pada tahap ini akan disusun kerangka optimasi usulan beserta kerangka pembanding lain yang diperoleh dari hasil observasi penulis. Kerangka kerja pembanding tersebut meliputi kerangka KNN-Kmeans [9], kerangka KNN-DBSCAN [7], dan kerangka KNN-HFSCE [4].

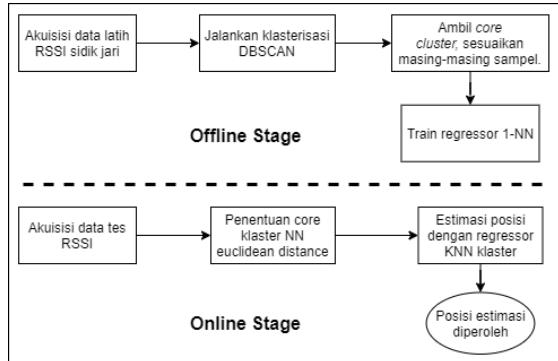
II.B.4.1) KNN-Kmeans



Gambar 13. Skema kerangka KNN-Kmeans.

Gambar 13 menunjukkan skema kerangka KNN-Kmeans. Kerangka ini menggunakan algoritma klasterisasi K-means pada tahap *offline* guna meningkatkan kinerja algoritma pencocokan KNN. Pada tahap *online*, vektor nilai RSSI kembali dikumpulkan untuk kemudian dibandingkan dengan model pencocokan KNN yang sebelumnya telah dibangun pada masing-masing klaster.

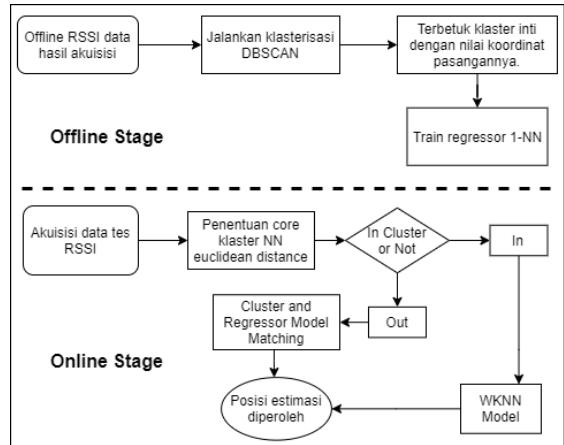
II.B.4.2) KNN-DBSCAN



Gambar 14. Skema kerangka KNN-DBSCAN.

Gambar 14 menunjukkan skema kerangka KNN-DBSCAN. Yang menjadi pembeda dengan KNN-Kmeans adalah proses pembentukan klaster pada *database* sidik jari dibentuk melalui pendekatan klasterisasi DBSCAN. Selain itu, penentuan klaster pada tahap *online* didekati dengan pencarian tetangga terdekat berbasis jarak *euclidean*.

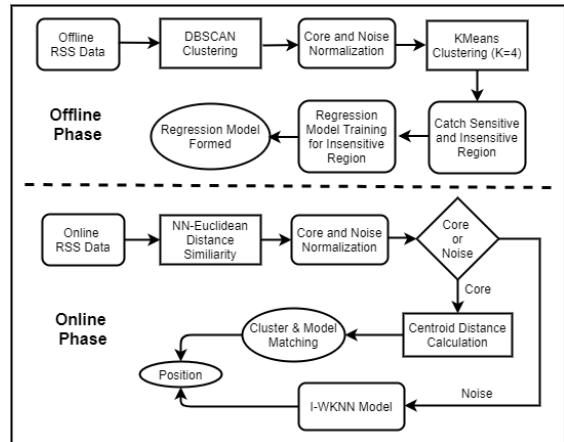
II.B.4.3) KNN-HFSCE



Gambar 15. Skema kerangka KNN-HFSCE.

Gambar 15 menunjukkan skema dari kerangka KNN-HFSCE. Kerangka ini disusun dengan menggunakan algoritma pengelompokan DBSCAN sebagai pendekatan tahap *offline* dan penggunaan algoritma pencocokan KNN bobot atau *Weighted KNN* (WKNN) pada tahap *online*. Kerangka ini juga menggunakan pencarian tetangga terdekat berbasis jarak *euclidean* untuk metode penentuan klaster pada tahap *online*.

II.B.4.4) DB-I-WKNN (*Proposed Method*)



Gambar 16. Skema kerangka DB-K-IWKNN.

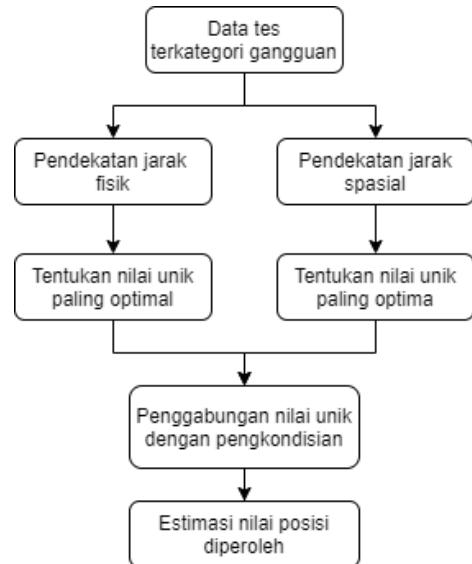
Gambar 16 menunjukkan skema dari kerangka DB-K-IWKNN. Kerangka ini dibangun dengan menggunakan algoritma pengelompokan *hybrid*

DBSCAN K-means sebagai pendekatan tahap *offline* dan algoritma perbaikan KNN bobot atau *Improved Weighted KNN* (I-WKNN) pada tahap *online*. Selain itu digunakan juga fungsi objektif jarak *manhattan* pada penggunaan model induk.

Pada tahap *offline*, klasterisasi DBSCAN dilakukan guna menyeleksi data gangguan. Setelah data gangguan diseleksi, selanjutnya adalah melakukan proses normalisasi data lewat penggunaan *Min-Max Normalization*. Langkah ini bertujuan untuk memberi rentang nilai yang seragam pada setiap fitur.

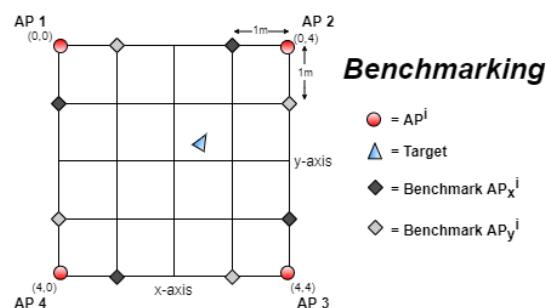
Kelompok data yang telah dinormalisasi kemudian dibentuk ke dalam sejumlah klaster baru lewat pengelompokan berbasis klasterisasi K-means empat klaster. Proses pembentukan klaster ini merupakan salah satu strategi pengoptimalan kinerja model dengan cara mengurangi kompleksitas data latih yang akan dipakai.

Penggunaan I-WKNN sebagai optimasi tahap *online* juga mampu memberikan efek signifikan terhadap peningkatan akurasi estimasi pemosisian. Hal ini dilatarbelakangi oleh tidak semua data yang diakusisi pada tahap *online* terkategori sebagai data klaster inti. Dalam penanganan data terkategori klaster inti, data akan diteruskan ke model pencocokan untuk melangsungkan proses estimasi. Sementara untuk penanganan data terkategori gangguan, algoritma I-WKNN diusulkan sebagai pendekatan estimasi yang dipilih (Gambar 17).



Gambar 17. Skema I-WKNN.

I-WKNN disusun dengan menggabungkan hasil pendekatan estimasi jarak fisik dan jarak spasial. Hal ini dilakukan untuk mengurangi ketergantungan algoritma terhadap proyeksi data spasial saja. Pendekatan jarak fisik dibangun lewat bantuan penggunaan model *pathloss* dengan koefisien *pathloss* beragam antara 2 – 4 bergantung pada skenario lingkungan uji. Hasil penggabungan ini nantinya akan berupa sekumpulan nilai unik koordinat yang paling mungkin merepresentasikan posisi objek sebenarnya. *Pseudocode* dari algoritma kerangka ini ditunjukkan pada Tabel 2. Pada Gambar 18 juga ditunjukkan visualisasi *benchmarking* sebagai alat bantu yang dipakai dalam penggunaan model *pathloss*.



Gambar 18. Skema *benchmarking*.

Tabel 2. Pseudocode I-WKNN

ALGORITMA 1: Pseudocode I-WKNN

Input : List titik koordinat *benchmark* AP_x^i dan AP_y^i , kelompok klaster inti sebelum normalisasi dan sesudah normalisasi, data tes terkategori gangguan, dan tabel referensi unik koordinat.

Output : Estimasi posisi saat ini.

1. Definisikan kelompok klaster inti sebelum normalisasi sebagai TRAIN_RAW, kelompok klaster inti setelah normalisasi sebagai TRAIN, data tes terkategori gangguan sebelum normalisasi sebagai TEST_RAW, data tes terkategori gangguan sesudah normalisasi sebagai TEST, dan tabel referensi unik koordinat sebagai REF_TABLE.
2. Untuk setiap vektor data dalam TEST_RAW :
 3. Untuk setiap AP^i dari total AP :
 4. Definisikan BM_x dan BM_y sebagai rerata nilai RSSI TRAIN_RAW pada *benchmark* AP_x^i dan AP_y^i .
 5. Dihitung jarak fisik antara vektor data terhadap BM_x dan BM_y lewat penggunaan model *pathloss*. Koefisien *pathloss* bervariasi antara 2 – 4 bergantung pada skenario lingkungan uji. Simpan hasil masing-masing dalam variabel D_1 dan D_2.
 6. Untuk setiap angka unik dalam kolom unik REF_TABLE :
 7. Definisikan UQ sebagai rerata nilai RSSI angka unik terhadap AP^i .
 8. Dihitung jarak fisik antara UQ terhadap BM_x dan BM_y lewat penggunaan model *pathloss*. Koefisien *pathloss* bervariasi antara 2 – 4 bergantung pada skenario lingkungan uji. Simpan jarak fisik bersama dengan nilai angka uniknya dalam variabel TEMP.
 9. Untuk setiap jarak fisik RP dalam TEMP :
 10. Dihitung jarak *manhattan* antara D_1 dan D_2 terhadap jarak fisik RP. Simpan hasil bersama-sama dengan nilai angka uniknya dalam variabel CLOS.
 11. Urutkan 35 titik teratas pada CLOS sebagai hasil pendekatan jarak fisik. Simpan dalam variabel PHY_DIS.
 12. Untuk setiap pair dalam PHY_DIS :
 13. Ambil empat nilai unik dengan frekuensi terbanyak. Simpan sebagai UNIQUE_PHY.
 - Catat pair baru UNIQUE_PHY dengan masing-masing jarak fisik-nya sebagai DISTANCE_PHY_SELECTION.
 14. Untuk setiap vektor data dalam TEST :
 15. Hitung jarak spasial vektor data terhadap seluruh TRAIN dengan algoritma WKNN 35
16. Dicari nilai unik koordinat hasil penggabungan DISTANCE_PHY_SELECTION & DISTANCE_SP_SELECTION dengan skema pengkondisian. Untuk setiap (P, S, DP, DS) dalam (UNIQUE_PHY, UNIQUE_SP, DISTANCE_PHY_SELECTION, DISTANCE_SP_SELECTION) :
 17. Jika hasil P dan S merujuk pada satu nilai unik koordinat. Ambil nilai tersebut sebagai estimasi posisi.
 18. Namun jika P dan S merujuk pada lebih dari satu nilai unik maka;
 19. Untuk setiap data dalam DS :
 - Jika nilai unik ada dalam perpotongan P dan S. Urutkan seluruh nilai tersebut dan catat nilai unik urutan pertama sebagai estimasi posisi.
 20. Yang lain apabila P dan S tidak merujuk pada nilai apapun, maka urutkan berdasarkan DS. Ambil nilai unik urutan pertama sebagai estimasi posisi.
 21. Nilai estimasi posisi total hasil IWKNN diperoleh.

III. HASIL DAN PEMBAHASAN

Hasil serta pembahasan dari usulan perancangan tersebut akan diuraikan ke dalam dua pokok bahasan meliputi; 1) Dasbor sistem akuisisi, dan 2) hasil pengujian kerangka optimasi.

III.A. Dasbor Sistem Akuisisi

Dasbor sistem akuisisi tersusun atas sejumlah panel informasi yang membantu proses pemantauan terhadap sejumlah variabel uji. Dari panel ini penulis dapat mengamati fenomena gangguan konstan atau fluktuatif yang dialami sinyal. Dari panel ini pula data di ekstrak ke dalam format CSV. Gambar 19 dan 20 menunjukkan visualisasi dasbor sistem akuisisi.



Gambar 19. Dasbor Client (1)



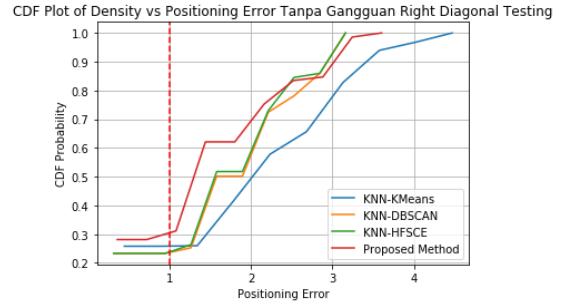
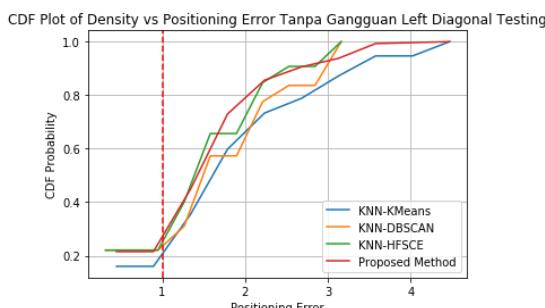
Gambar 20. Dasbor Client (2)

III.B. Pengujian Kerangka Optimasi

III.B.1 Skenario Tanpa Gangguan

Hasil pengujian menunjukkan bahwa kerangka optimasi usulan unggul terhadap kerangka pembanding KNN-Kmeans, KNN-DBSCAN, dan KNN HFSCE dengan penurunan rerata RMSE pemasision masing-masing sebesar 21.65%, 14.29%, dan 3.44% pada uji diaonal kiri, serta 21.51%, 10.62%, dan 7.55% pada uji diagonal kanan.

Hasil penggambaran grafik *cumulative distribution function* (CDF) pada Gambar 21 menunjukkan bahwa kerangka optimasi usulan memberikan rerata eror pemasision 28% dibawah 1 m pada uji diagonal kiri dan 30% dibawah 1 m pada uji diagonal kanan.

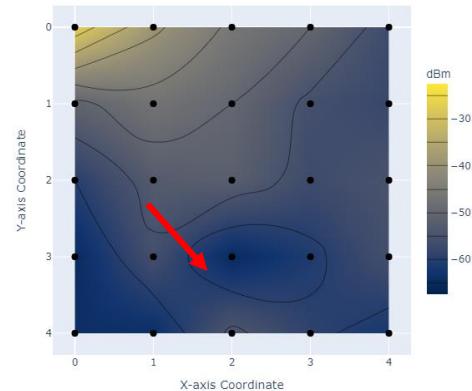


Gambar 21. Plot CDF uji diagonal kiri (atas) dan kanan (bawah) lingkungan tanpa gangguan

III.B.2 Skenario Lingkungan Dengan Objek Penghalang

Gambar 22 menunjukkan distribusi rerata nilai RSSI pada lingkungan dengan objek penghalang. Gradiasi warna yang semakin biru menandakan penurunan kuat sinyal yang semakin besar. Pada proyeksi terhadap AP 1 dapat diamati bahwa sekitar titik (2,3) terdapat penurunan nilai kuat sinyal. Hal ini mengindikasikan adanya *blocking* sinyal di sekitar titik tempat objek penghalang diletakkan.

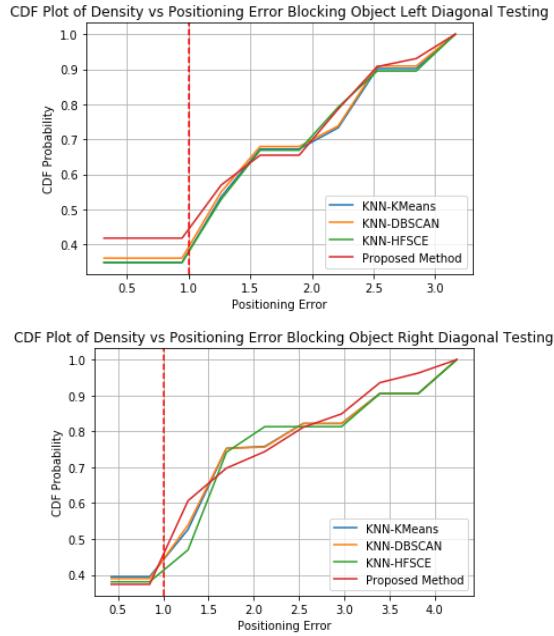
Mean RSSI Objek Penghalang Terhadap AP 1



Gambar 22. Peta distribusi rerata RSSI lingkungan dengan objek penghalang.

Hasil pengujian menunjukkan bahwa kerangka optimasi usulan unggul terhadap kerangka pembanding KNN-Kmeans, KNN-DBSCAN, dan KNN HFSCE dengan penurunan rerata RMSE pemasision masing-masing sebesar 8.26%, 5.86%, dan 8.08% pada uji diagonal kiri, serta 1.64%, 1.69%, dan 4.51% pada uji diagonal kanan.

Hasil penggambaran grafik CDF pada Gambar 23 menunjukkan bahwa kerangka optimasi usulan memberikan rerata eror pemosisian 42% dibawah 1 m pada uji diagonal kiri dan 48% dibawah 1 m pada uji diagonal kanan.

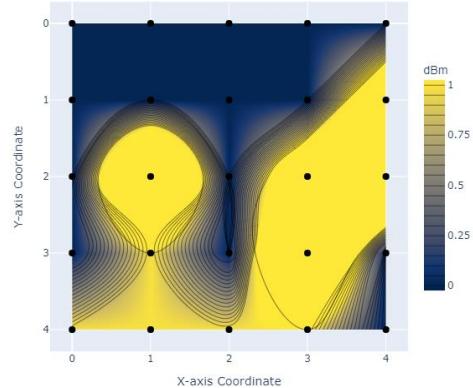


Gambar 23. Plot CDF uji diagonal kiri (atas) dan kanan (bawah) lingkungan dengan objek penghalang.

III.B.3 Skenario Gangguan Fluktuatif Pusat

Gambar 24 menunjukkan distribusi variansi nilai RSSI pada lingkungan dengan gangguan fluktuatif pusat. Gradasi warna yang semakin kuning menandakan fluktuatif kuat sinyal yang semakin besar. Perubahan besar nilai variansi dapat diamati dengan jelas pada proyeksi terhadap AP 3.

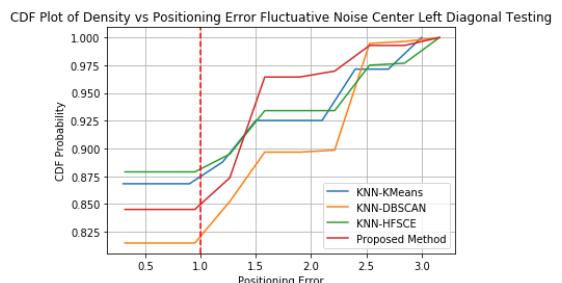
Variansi RSSI Fluktuatif Pusat Terhadap AP 3

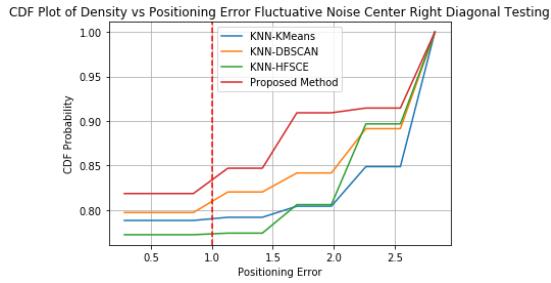


Gambar 24. Peta distribusi variansi RSSI lingkungan dengan gangguan fluktuatif pusat.

Hasil pengujian menunjukkan bahwa kerangka optimasi usulan unggul terhadap kerangka pembanding KNN-Kmeans, KNN-DBSCAN, dan KNN HFSCE dengan penurunan rerata RMSE pemosisian masing-masing sebesar 7.27%, 27.86%, dan 0% pada uji diagonal kiri, serta 32.57%, 21.64% dan 31.09% pada uji diagonal kanan. Dapat diamati bahwa terhadap KNN-HFSCE pada uji diagonal kiri, kerangka optimasi masih belum menunjukkan adanya penurunan rerata RMSE.

Hasil penggambaran grafik CDF pada Gambar 25 menunjukkan bahwa kerangka optimasi usulan memberikan rerata eror pemosisian 85% dibawah 1 m pada uji diagonal kiri dan 84% dibawah 1 m pada uji diagonal kanan.

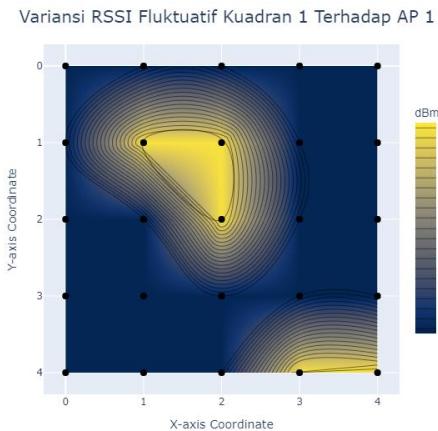




Gambar 25. Plot CDF uji diagonal kiri (atas) dan kanan (bawah) lingkungan dengan gangguan fluktuatif pusat

III.B.4 Skenario Gangguan Fluktuatif Kuadran Satu

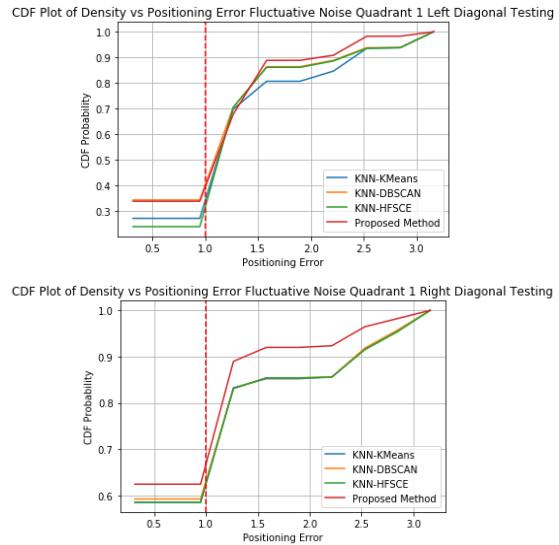
Gambar 26 menunjukkan distribusi variansi nilai RSSI pada lingkungan dengan gangguan fluktuatif kuadran satu. Perubahan besar nilai variansi dapat diamati dengan jelas pada koordinat (1,1) dengan proyeksi terhadap AP 1.



Gambar 26. Peta distribusi variansi RSSI lingkungan dengan gangguan fluktuatif kuadran satu

Hasil pengujian menunjukkan bahwa kerangka optimasi usulan unggul terhadap kerangka pembanding KNN-Kmeans, KNN-DBSCAN, dan KNN HFSCE dengan penurunan rerata RMSE pemasian masing-masing sebesar 15.44%, 4.69% dan 14.46% pada uji diagonal kiri, serta 23.27%, 22.22% dan 23.42% pada uji diagonal kanan.

Hasil penggambaran grafik CDF pada Gambar 27 menunjukkan bahwa kerangka optimasi usulan memberikan rerata eror pemasian 36% dibawah 1 m pada uji diagonal kiri dan 63% dibawah 1 m pada uji diagonal kanan.

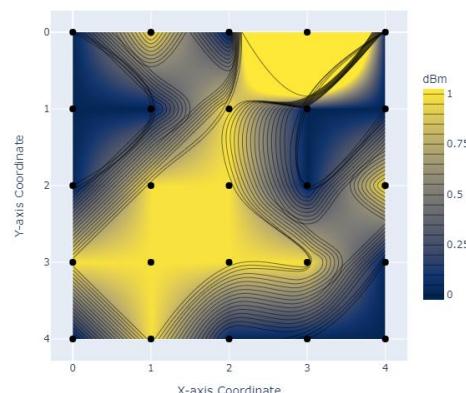


Gambar 27. Plot CDF uji diagonal kiri (atas) dan kanan (bawah) lingkungan dengan gangguan fluktuatif kuadran satu.

III.B.5 Skenario Gangguan Fluktuatif Kuadran Tiga

Gambar 28 menunjukkan distribusi variansi nilai RSSI pada lingkungan dengan gangguan fluktuatif kuadran tiga. Perubahan nilai variansi dapat diamati pada proyeksi terhadap AP 1 dengan pengaruh tidak hanya pada titik (3,3) namun juga pada titik-titik tetangganya.

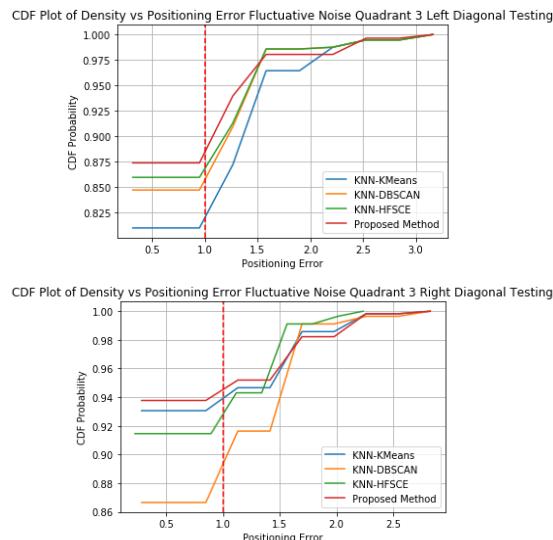
Variansi RSSI Fluktuatif Kuadran 3 Terhadap AP 1



Gambar 28. Peta distribusi variansi RSSI lingkungan dengan gangguan fluktuatif kuadran tiga.

Hasil pengujian menunjukkan bahwa kerangka optimasi usulan unggul terhadap kerangka pembanding KNN-Kmeans, KNN-DBSCAN, dan KNN-HFSCE dengan penurunan rerata RMSE pemosisian masing-masing sebesar 37.26%, 17.43% dan 11.47% pada uji diagonal kiri, serta 5.32%, 43.77% dan 13.85% pada uji diagonal kanan.

Hasil penggambaran grafik CDF pada Gambar 29 menunjukkan bahwa kerangka optimasi usulan memberikan rerata eror pemosisian 88% dibawah 1 m pada uji diagonal kiri dan 94% dibawah 1 m pada uji diagonal kanan.



Gambar 29. Plot CDF uji diagonal kiri (atas) dan kanan (bawah) lingkungan dengan gangguan fluktuatif kuadran tiga.

IV. KESIMPULAN

Pada penelitian ini memberi kesimpulan bahwa, kerangka optimasi usulan (DB-K-IWKNN) sukses dirancang dan dibangun, serta memberikan hasil menurunkan nilai rerata eror pemosisian pada sembilan dari sepuluh skenario pengujian yang diujikan, relatif terhadap kerangka pembanding KNN-Kmeans, KNN-DBSCAN, KNN-HFSCE, masing-masing sebesar 17.97%, 14.03%, 9.36%.

pada uji diagonal kiri, serta 16.86%, 19.99%, 16.09% pada uji diagonal kanan.

UCAPAN TERIMA KASIH

Puji syukur atas kehadirat Allah SWT yang telah melimpahkan rahmat serta hidayah-Nya sehingga penulis dapat menyelesaikan skripsi dengan judul “DB-K-IWKNN: Optimasi Kerangka Kerja Metode Sidik Jari Pada Teknik Pemosisian Objek Dalam Ruang Berbasis Wi-Fi” yang merupakan syarat kelulusan Sarjana S-1 Departemen Teknik Nuklir dan Teknik Fisika, Fakultas Teknik, Universitas Gadjah Mada. Ucapan terima kasih disampaikan kepada Bapak Dwi Joko Suroso S.T., M.Eng dan Bapak Muhammad Reza Kahar Aziz, ST, MT, PhD. selaku dosen pendamping tugas akhir. Ucapan terima kasih terkhusus juga diberikan kepada Bapak Dwi Joko Suroso S.T., M.Eng yang telah memberikan bantuan alat penelitian sehingga penulis dapat menggunakan perangkat ESP32 dalam penelitian ini.

DAFTAR PUSTAKA

- [1] O. Kerem, B. Ayhan dan I. Tekin, “Indoor positioning based on global positioning system signals,” *Microw. Opt. Technol. Lett.*, pp. 1091-1097, 2013.
- [2] F. Zafari, A. Gkelias dan K. K. Leung, “A Survey of Indoor Localization Systems and Technologies,” *IEEE Communications Surveys & Tutorials*, vol. 21, pp. 2568-2599, 2019.
- [3] K. Yu dan Y. J. Guo, “Statistical NLOS Identification Based on AOA, TOA, and Signal Strength,” *IEEE Transactions on Vehicular*

- Technology*, vol. 58, pp. 274-286, 2009.
- [4] H. Li, J. K. Ng dan K. Liu, “Handling Fingerprint Sparsity for Wi-Fi Based Indoor Localization in Complex Environments,” *IEEE SmartWorld, Ubiquitous Intelligence & Computing, Advanced & Trusted Computing, Scalable Computing & Communications, Cloud & Big Data Computing, Internet of People and Smart City Innovation (SmartWorld/SCALCOM/UIC/ATC/CBDCom/IOP/SCI)*, pp. 1109-1116, 2019.
- [5] A. Abusara, M. S. Hassan dan M. H. Ismail, “Reduced-complexity fingerprinting in WLAN-based indoor positioning,” *Telecommun Syst*, p. 407–417, 2017.
- [6] W. Xue, X. Hua, Q. Li, K. Yu, W. Qiu, B. Zhou dan K. Cheng, “A New Weighted Algorithm Based on the Uneven Spatial Resolution of RSSI for Indoor Localization,” *IEEE Access*, vol. 6, pp. 26588-26595, 2018.
- [7] S. Hu, “Indoor Location Method Based on Data Mining,” dalam *ICSCC 2019: Proceedings of the 2019 5th International Conference on Systems, Control and Communications*, 2019.
- [8] F. Lemic, V. Handziski, M. Aernouts, T. Janssen, R. Berkvens, A. Wolisz dan J. Famaey, “Regression-Based Estimation of Individual Errors in Fingerprinting Localization,” *IEEE Access*, vol. 7, pp. 33652-33664, 2019.
- [9] B. Altintas dan T. Serif, “Improving RSS-Based Indoor Positioning Algorithm via K-Means Clustering,” dalam *Wireless Conference 2011 - Sustainable Wireless Technologies (European Wireless), 11th European*, 2011.